

Churn em e-commerce: auditoria de dados, correlações entre fatores e modelos de cancelamento

João Gabriel Tavares Silva[1]

Universidade de Brasília (UnB)

RESUMO

Este trabalho analisa uma base pública de 50.000 clientes de comércio eletrônico, com 25 variáveis de perfil, engajamento, compras e atrito, para identificar fatores associados ao cancelamento (*churn*), que atinge 28,9% dos clientes. A auditoria mostrou que a base é simulada: dados faltantes em proporções redondas exatas, geografia e cadastro distribuídos de forma perfeita e 451 clientes com valores impossíveis inseridos. Os resultados valem, portanto, como estudo de método. Valores extremos distorcem a correlação de Pearson (ticket médio $\times$ valor do cliente: 0,15 em Pearson, 0,56 em Spearman). Um único fator de engajamento explica 36,5% da variância das 20 variáveis numéricas, e, controlado esse fator, as oito medidas de engajamento perdem quase toda a correlação com o churn. Os sinais mais fortes são de atrito: o churn vai de 12% a 47% entre o quintil mais baixo e o mais alto de ligações ao atendimento. Um modelo de *gradient boosting* (AUC = 0,93) supera a regressão logística (AUC = 0,79) porque capta relações não lineares, como o churn em forma de U ao longo do valor do cliente.

Palavras-chave: churn; comércio eletrônico; qualidade de dados; correlação; gradient boosting.

ABSTRACT

This paper analyzes a public dataset of 50,000 e-commerce customers, with 25 profile, engagement, purchase and friction variables, to identify factors associated with churn, which affects 28.9% of customers. The audit showed that the dataset is simulated: missing values in exact round proportions, perfectly balanced geography and sign-up dates, and 451 customers with injected impossible values. The results therefore stand as a methodological study. Extreme values distort Pearson correlation (average order value $\times$ customer value: 0.15 in Pearson, 0.56 in Spearman). A single engagement factor explains 36.5% of the variance

[1] Aluno da Universidade de Brasília (UnB). Matrícula: 221021071.

of the 20 numeric variables, and, once it is controlled for, the eight engagement measures lose almost all their correlation with churn. The strongest signals relate to friction: churn rises from 12% to 47% between the lowest and highest quintile of customer service calls. A gradient boosting model (AUC = 0.93) outperforms logistic regression (AUC = 0.79) because it captures non-linear relationships, such as the U-shaped churn along customer lifetime value.

Keywords: churn; e-commerce; data quality; correlation; gradient boosting.

1 INTRODUÇÃO

Reter um cliente costuma custar menos do que conquistar outro, e por isso prever o cancelamento (*churn*) é um dos usos mais comuns de dados em comércio eletrônico. Bases públicas de churn circulam amplamente em plataformas como o Kaggle e são usadas em cursos e trabalhos acadêmicos, muitas vezes sem verificação da origem ou da qualidade dos dados.

O trabalho responde a três perguntas. Primeiro, a base é confiável e o que precisa ser corrigido antes da análise? Segundo, como os fatores de perfil, engajamento, compras e atrito se relacionam entre si? Terceiro, quais fatores estão associados ao churn, e essa associação é linear?

A contribuição é metodológica. O trabalho mostra como identificar uma base simulada, como valores extremos e variáveis redundantes enganam a análise de correlação e por que modelos lineares podem esconder o fator mais importante. O código completo e interativo está em um notebook público (SILVA, 2026).

2 DADOS E MÉTODO

2.1 Base de dados

A base reúne 50.000 clientes de uma loja on-line em 8 países e 40 cidades (SRISYRA02, [2026?]). As 25 variáveis foram agrupadas em quatro blocos: perfil (idade, gênero, país, tempo de cadastro), engajamento (logins, duração da sessão, páginas, app, e-mails, redes sociais, lista de desejos, avaliações), compras (total, ticket médio, recência, descontos, devoluções, meios de pagamento, valor do cliente ou LTV, saldo de crédito) e atrito (abandono de carrinho, ligações ao atendimento). A variável de interesse indica se o cliente cancelou; a taxa geral é de 28,9%. Não há datas, apenas o trimestre de cadastro, o que faz da base um corte transversal.

2.2 Auditoria

A conferência da base encontrou sinais consistentes de geração sintética (Tabela 1).

A falta de dado não é aleatória em duas variáveis. Clientes sem duração de sessão registrada têm churn de 41,1%, contra 28,0% dos demais; sem taxa de abertura de e-mails, 40,7% contra 28,3% (qui-quadrado com correção de Benjamini e Hochberg, $p < 0{,}001$). Excluir essas linhas enviesaria a análise (LITTLE; RUBIN, 2019).

Tabela 1 – Evidências de que a base é simulada

Evidência	**O que se observa**
Faltantes em proporções redondas	5,0%, 6,0%, 7,0%, 8,0%, 10,0%, 11,0% e 12,0% em colunas diferentes
Geografia artificial	Exatamente 5 cidades por país, sempre as maiores
Cadastro uniforme	Entre 24,9% e 25,1% dos clientes em cada trimestre
Erros inseridos	Idades de 5, 10, 150 e 200 anos; compras negativas; taxas acima de 100% (451 clientes no total)
Contagem com decimais	22,5% dos clientes com total de compras fracionário
Correlações do tipo tudo ou nada	Dos 190 pares, 111 com correlação abaixo de 0,1 em módulo, 78 acima de 0,3 e só 1 entre os dois

Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]).

2.3 Limpeza

Valores impossíveis (idade fora de 16 a 100 anos, compras negativas, taxas acima de 100%) foram convertidos em faltantes. Extremos plausíveis, como tickets acima de US$ 1.000, foram mantidos, e por isso as análises usam medidas robustas a eles. Nos modelos, faltantes foram imputados pela mediana com uma variável indicadora de falta.

2.4 Medidas e modelos

As correlações entre os 190 pares de variáveis numéricas foram medidas por Pearson e por Spearman (1904), que usa a ordem dos valores e resiste a extremos, com correção de Benjamini e Hochberg (1995) para múltiplas comparações. A estrutura comum foi estimada por componentes principais, e a correlação parcial com o churn foi calculada controlando o primeiro componente. As variáveis categóricas foram avaliadas pelo V de Cramér (1946).

Para o churn, compararam-se uma regressão logística com variáveis padronizadas e um modelo de *gradient boosting* (FRIEDMAN, 2001), ambos por validação cruzada estratificada em cinco partes e medidos pela área sob a curva ROC (AUC). A importância das variáveis foi medida por permutação em uma amostra de teste de 25%.

3 RESULTADOS

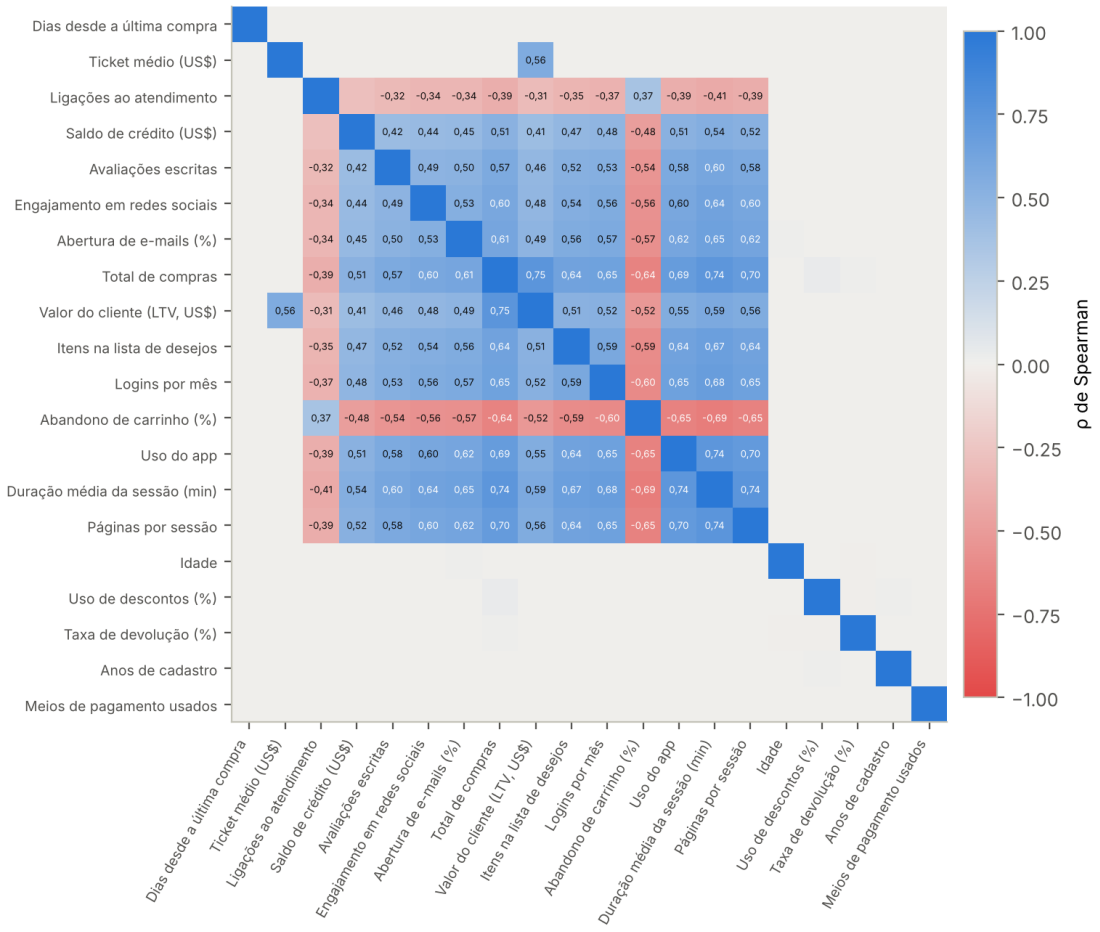
3.1 Correlações entre pares

Valores extremos alteram a correlação de Pearson nos dois sentidos. Entre ticket médio e valor do cliente (LTV), Pearson indica 0,15 e Spearman 0,56: 25 tickets acima de US$ 1.000 achatam a relação linear. Entre total de compras e taxa de devolução ocorre o inverso: Pearson indica 0,28, criado por poucos extremos, e Spearman 0,01. Por isso as análises seguintes usam Spearman na base limpa.

As variáveis formam um bloco fortemente ligado (Figura 1). Os pares mais fortes são total de compras $\times$ LTV ($\rho = 0{,}75$), duração da sessão $\times$ páginas por sessão (0,74) e duração da

sessão × uso do app (0,74). O abandono de carrinho é o espelho negativo desse bloco: $\rho = -0{,}69$ com a duração da sessão. O primeiro componente principal, um fator de engajamento, explica 36,5% da variância das 20 variáveis, contra cerca de 5% se elas fossem independentes.

Figura 1 – Correlação de Spearman entre as 20 variáveis numéricas, ordenadas por agrupamento hierárquico



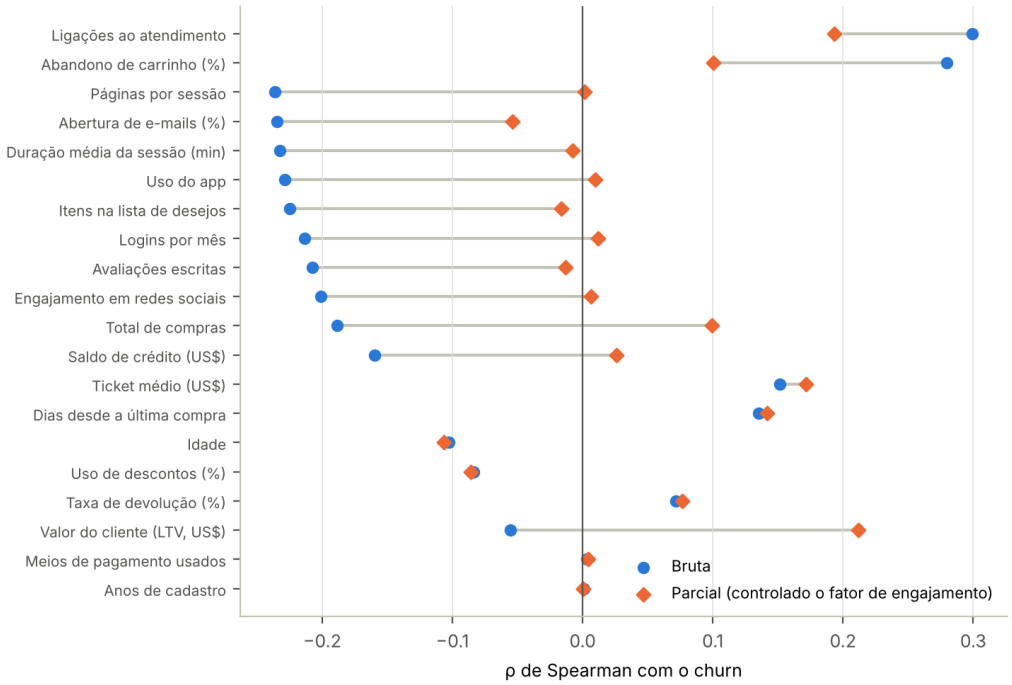
Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]). Valores exibidos apenas quando o módulo de ρ é de pelo menos 0,3.

O perfil demográfico praticamente não se relaciona com o churn. Entre países, a taxa vai de 27,3% a 29,9%; entre gêneros, de 28,7% a 31,3%; e o V de Cramér fica abaixo de 0,02 em país, gênero e trimestre de cadastro.

3.2 Fatores associados ao churn

A correlação bruta com o churn é negativa para todas as medidas de engajamento, entre $-0{,}20$ e $-0{,}24$. Controlado o fator de engajamento, porém, essas correlações caem para perto de zero (Figura 2): as oito variáveis medem a mesma coisa. Os fatores que mantêm associação própria são as ligações ao atendimento, o ticket médio, a recência da última compra e a idade (Tabela 2).

Figura 2 – Correlação de Spearman com o churn: bruta e parcial (controlado o fator de engajamento)



Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]).

Tabela 2 – Churn por quintil e correlação com o churn, variáveis selecionadas

Variável	**Churn no 1º quintil**	**Churn no 5º quintil**	**ρ bruta**	**ρ parcial**
Ligações ao atendimento	12%	47%	+0,30	+0,19
Abandono de carrinho	19%	57%	+0,28	+0,10
Duração média da sessão	49%	19%	−0,23	−0,01
Abertura de e-mails	50%	18%	−0,23	−0,05
Dias desde a última compra	22%	40%	+0,14	+0,14
Valor do cliente (LTV)	45%	38%	−0,06	+0,21
Anos de cadastro	28%	29%	0,00	0,00

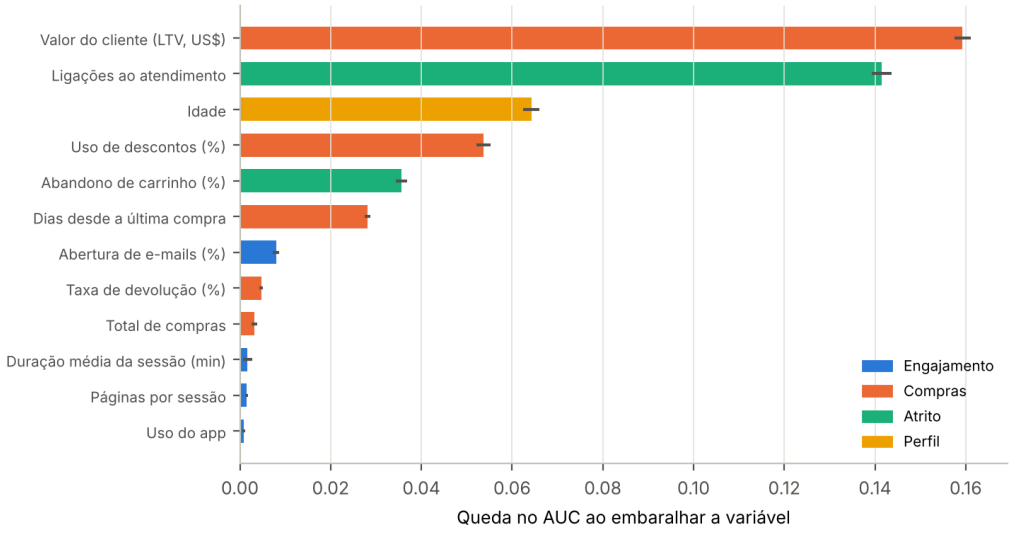
Fonte: Elaboração própria. Quintil 1 = 20% dos clientes com menor valor da variável. Taxa média de churn: 28,9%.

O LTV merece destaque. Sua correlação com o churn é quase nula ($-0{,}06$), mas a relação tem forma de U: 45% de churn no quintil mais baixo, 17% no do meio e 38% no mais alto. Uma correlação, por resumir a relação numa reta, não enxerga esse padrão. Na regressão logística, o coeficiente do LTV ainda muda de sinal (+0,81) quando o total de compras entra no modelo, um efeito de supressão: o LTV passa a medir o valor gasto por compra.

3.3 Modelos

O *gradient boosting* teve AUC de 0,927 (desvio-padrão de 0,005 entre as cinco partes da validação cruzada), contra 0,790 (0,004) da regressão logística. A diferença de 0,14 indica que boa parte da relação com o churn é não linear. Na importância por permutação, o LTV e as ligações ao atendimento dominam: embaralhar cada um reduz o AUC em 0,16 e 0,14, respectivamente, contra 0,06 da idade e 0,05 do uso de descontos (Figura 3).

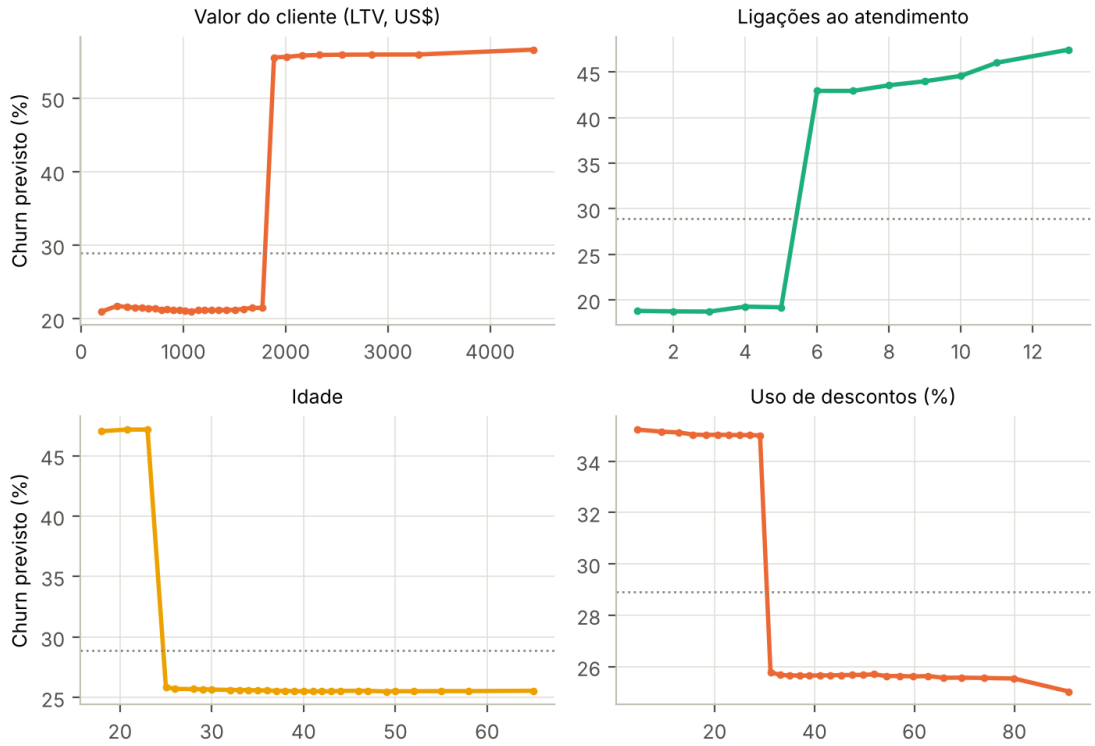
Figura 3 – Importância das variáveis no modelo de *gradient boosting* (queda no AUC ao embaralhar cada variável)



Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]). AUC no conjunto de teste = 0,931. As 12 variáveis mais importantes; barras de erro = desvio-padrão em 5 repetições.

A dependência parcial mostra por que o modelo de árvores vence: os efeitos são degraus, não retas (Figura 4). O churn previsto salta de 19% para 43% entre 5 e 6 ligações ao atendimento e de 21% para 56% quando o LTV passa de cerca de US$ 1.800; cai de 47% para 26% quando a idade passa de 24 anos e de 35% para 26% quando o uso de descontos passa de 30%. Degraus tão nítidos, em valores redondos, são mais um indício de que o gerador da base definiu o churn por regras de corte. Condicionado às demais variáveis, o LTV tem um único degrau; o U observado na Tabela 2 vem de clientes de LTV baixo que também engajam menos.

Figura 4 – Dependência parcial: churn previsto ao longo das quatro variáveis mais importantes



Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]). Linha pontilhada = taxa média de churn (28,9%).

4 DISCUSSÃO E LIMITAÇÕES

O primeiro resultado é sobre a própria base. Uma auditoria simples, com contagem de faltantes, faixas de valores e distribuição das categorias, bastou para mostrar que os dados são simulados. Bases desse tipo são úteis para ensino, mas conclusões sobre o comportamento de consumidores reais exigiriam dados coletados. A auditoria também revelou que a falta de dado carrega informação: descartar as linhas incompletas teria retirado justamente clientes com mais churn.

O segundo resultado é sobre a leitura de correlações. Oito variáveis de engajamento parecem fatores distintos de retenção quando vistas uma a uma, mas são versões de um mesmo comportamento. Para a gestão, isso significa que acompanhar oito indicadores de engajamento acrescenta pouco a acompanhar um índice que os resuma. Já os sinais de atrito, como ligações ao atendimento e abandono de carrinho, têm associação própria com o churn e apontam para pontos de intervenção no processo de atendimento e de compra.

O terceiro resultado é sobre modelos. A regressão logística é interpretável, mas supõe efeitos lineares e perdeu 0,14 de AUC para o modelo de árvores. O caso do LTV mostra o custo dessa suposição: a variável mais importante do modelo não linear parecia irrelevante na correlação e tinha coeficiente de sinal contraintuitivo na regressão.

Há três limitações principais. A base é simulada, e as relações encontradas refletem as

regras do gerador dos dados. Os dados são de corte transversal, sem datas, o que impede saber se a queda de engajamento antecede o cancelamento. E associação não implica causalidade: ligações ao atendimento podem ser sintoma, e não causa, da insatisfação.

5 CONCLUSÃO

A base analisada é simulada, e reconhecer isso foi o primeiro resultado do trabalho. Nela, o churn de 28,9% não depende do perfil demográfico, mas de um fator geral de engajamento, de sinais de atrito (ligações ao atendimento e abandono de carrinho) e, de forma não linear, do valor do cliente. Três cuidados de método mudaram as conclusões: usar correlações robustas a extremos, controlar variáveis redundantes e testar modelos não lineares. Sem eles, o fator mais importante do churn, o LTV, teria parecido irrelevante.

REFERÊNCIAS

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, v. 57, n. 1, p. 289–300, 1995.

CRAMéR, H. *Mathematical methods of statistics*. Princeton: Princeton University Press, 1946.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

LITTLE, R. J. A.; RUBIN, D. B. *Statistical analysis with missing data*. 3. ed. Hoboken: Wiley, 2019.

SILVA, J. G. T. *Análise de churn em e-commerce*. 2026. Notebook Jupyter. GitHub. Disponível em: <https://github.com/joaogabrielts0611-ai/analise-churn-ecommerce>. Acesso em: 5 nov. 2026.

SPEARMAN, C. The proof and measurement of association between two things. *The American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.

SRISYRA02. *Ecommerce customer behavior dataset*: a comprehensive analysis of customer behavior and engagement patterns. [2026?]. Kaggle. Base de dados. Disponível em: <https://www.kaggle.com/datasets/srisyra02/ecommerce-customer-behavior-dataset>. Acesso em: 5 nov. 2026.