

Churn em e-commerce: auditoria de dados, correlações entre fatores e modelos de cancelamento

João Gabriel Tavares Silva

Universidade de Brasília (UnB) · Matrícula: 221021071

RESUMO

Este trabalho analisa uma base pública de 50.000 clientes de comércio eletrônico, com 25 variáveis de perfil, engajamento, compras e atrito, para identificar fatores associados ao cancelamento (*churn*), que atinge 28,9% dos clientes. A auditoria mostrou que a base é simulada, e os resultados valem como estudo de método. Valores extremos distorcem a correlação de Pearson (ticket médio × valor do cliente: 0,15 em Pearson, 0,56 em Spearman). Um único fator de engajamento explica 36,5% da variância das 20 variáveis numéricas e, controlado esse fator, as oito medidas de engajamento perdem quase toda a correlação com o churn. Os sinais mais fortes são de atrito: o churn vai de 12% a 47% entre o quintil mais baixo e o mais alto de ligações ao atendimento. Um modelo de *gradient boosting* (AUC = 0,93) supera a regressão logística (AUC = 0,79) porque capta efeitos não lineares.

Palavras-chave: churn; comércio eletrônico; qualidade de dados; correlação; gradient boosting.

ABSTRACT

This paper analyzes a public dataset of 50,000 e-commerce customers, with 25 profile, engagement, purchase and friction variables, to identify factors associated with churn, which affects 28.9% of customers. The audit showed that the dataset is simulated, so the results stand as a methodological study. Extreme values distort Pearson correlation (average order value × customer value: 0.15 in Pearson, 0.56 in Spearman). A single engagement factor explains 36.5% of the variance of the 20 numeric variables and, once it is controlled for, the eight engagement measures lose almost all their correlation with churn. The strongest signals relate to friction: churn rises from 12% to 47% between the lowest and highest quintile of customer service calls. A gradient boosting model (AUC = 0.93) outperforms logistic regression (AUC = 0.79) because it captures non-linear effects.

Keywords: churn; e-commerce; data quality; correlation; gradient boosting.

1 INTRODUÇÃO

Prever o cancelamento (*churn*) é um dos usos mais comuns de dados em comércio eletrônico. Bases públicas de churn circulam amplamente em plataformas como o Kaggle e são usadas em cursos e trabalhos acadêmicos, muitas vezes sem verificação da origem ou da qualidade dos dados.

O trabalho responde a três perguntas: se a base é confiável e o que precisa ser corrigido antes da análise; como os fatores de perfil, engajamento, compras e atrito se relacionam entre si; e quais fatores estão associados ao churn, e se essa associação é linear. O código completo e interativo está em um notebook público (SILVA, 2026) (GitHub · Google Colab).

2 REVISÃO DE LITERATURA

O interesse gerencial pelo churn vem do valor da retenção. Reichheld e Sasser (1990) mostraram, em empresas de serviços, que reduzir em 5 pontos percentuais a taxa de perda de clientes pode elevar o lucro em 25% a 85%, porque clientes antigos compram mais e custam menos para atender. A partir daí, prever quem vai cancelar virou problema central do marketing analítico.

No torneio de modelos de churn analisado por Neslin et al. (2006), a escolha do método de estimação mudou de forma relevante a capacidade de previsão, com vantagem para regressão logística e árvores de decisão sobre abordagens mais simples. Lemmens e Croux (2006) mostraram que combinar árvores por *bagging* e *boosting* melhora de forma substancial a previsão de churn em relação a uma árvore única ou à regressão logística, por captar interações e efeitos não lineares. O *gradient boosting* de Friedman (2001) é a forma mais usada dessa ideia. Verbeke et al. (2012) acrescentam que, além da precisão, modelos de churn precisam ser compreensíveis para orientar a ação de retenção, o que justifica comparar um modelo interpretável com um mais flexível.

Dois cuidados de método completam a revisão. Quando a falta de dado está associada ao resultado, excluir as linhas incompletas enviesa as estimativas (LITTLE; RUBIN, 2019). E correlações de Pearson são sensíveis a valores extremos, enquanto a correlação por postos de Spearman (1904) mede associações monotônicas e resiste a eles.

3 METODOLOGIA

A base reúne 50.000 clientes de uma loja on-line em 8 países e 40 cidades (SRISYRA02, [2026?]), com 25 variáveis em quatro blocos: perfil (idade, gênero, país, tempo de cadastro), engajamento (logins, duração da sessão, páginas, app, e-mails, redes sociais, lista de desejos, avaliações), compras (total, ticket médio, recência, descontos, devoluções, valor do cliente ou LTV, saldo de crédito) e atrito (abandono de carrinho, ligações ao atendimento). Não há datas, o que faz da base um corte transversal.

A auditoria encontrou sinais consistentes de geração sintética: faltantes em proporções redondas exatas (5,0%, 6,0%, 7,0% e outras) em colunas diferentes; exatamente 5 cidades por país; cadastros distribuídos entre 24,9% e 25,1% por trimestre; 451 clientes com valores impossíveis inseridos (idades de 5 e 200 anos, compras negativas); e correlações do tipo tudo ou nada, com só 1 dos 190 pares entre 0,1 e 0,3 em módulo. A falta de dado é informativa em duas variáveis: sem duração de sessão registrada, o churn é de 41,1%, contra 28,0% dos demais ($p < 0{,}001$).

Por isso, valores impossíveis foram convertidos em faltantes, extremos plausíveis foram mantidos e, nos modelos, faltantes foram imputados pela mediana com uma variável indicadora de falta. As correlações entre os 190 pares foram medidas por Pearson e Spearman, com correção de Benjamini e Hochberg (1995); a estrutura comum, por componentes principais; e a correlação parcial com o churn, controlando o primeiro componente. As variáveis categóricas foram avaliadas pelo V de Cramér (1946). Para o churn, compararam-se regressão logística e *gradient boosting* por validação cruzada estratificada em cinco partes, medidos pela área sob a curva ROC (AUC), com importância das variáveis por permutação e dependência parcial.

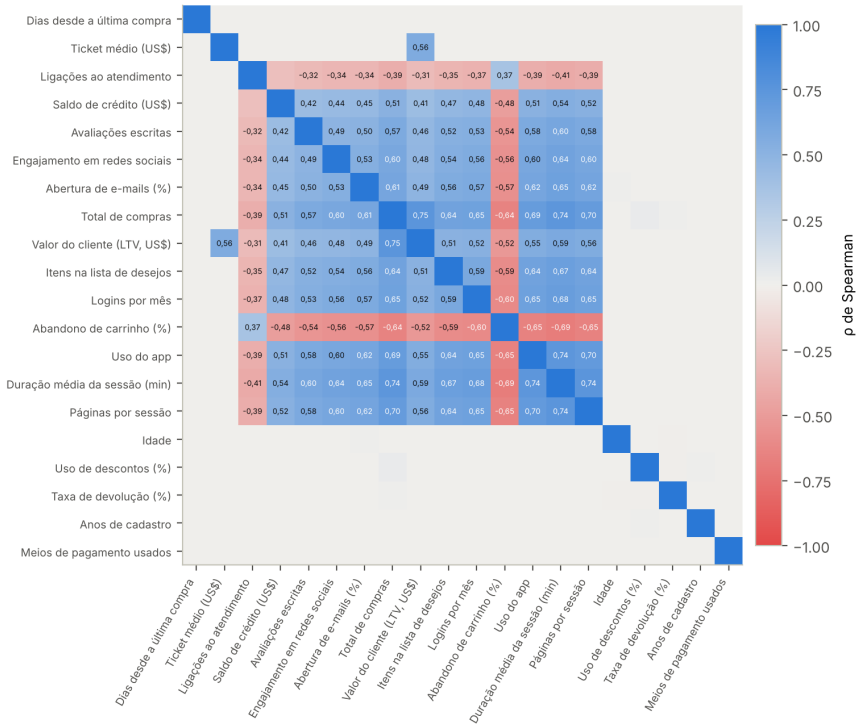
4 RESULTADOS ENCONTRADOS

Valores extremos alteram Pearson nos dois sentidos. Entre ticket médio e LTV, Pearson indica 0,15 e Spearman 0,56: 25 tickets acima de US$ 1.000 achatam a relação linear. Entre total de compras e taxa de devolução ocorre o inverso: 0,28 em Pearson, criado por poucos extremos, e 0,01 em Spearman. As variáveis formam um bloco fortemente ligado (Figura 1): total de compras $\times$ LTV ($\rho = 0{,}75$), duração da sessão $\times$ páginas (0,74) e abandono de carrinho como espelho negativo ($\rho = -0{,}69$ com a duração da sessão). O primeiro componente principal, um fator de engajamento, explica 36,5% da variância, contra cerca de 5% com variáveis independentes. Já o perfil demográfico quase não se relaciona com o churn: V de Cramér abaixo de 0,02 em país, gênero e trimestre de cadastro.

A correlação bruta com o churn é negativa para todas as medidas de engajamento, entre $-0{,}20$ e $-0{,}24$, mas cai para perto de zero quando se controla o fator de engajamento: as oito variáveis medem a mesma coisa. Mantêm associação própria as ligações ao atendimento, a recência da última compra e o LTV (Tabela 1). O LTV tem correlação bruta quase nula, mas relação em U: 45% de churn no quintil mais baixo, 17% no do meio e 38% no mais alto, padrão que uma correlação linear não enxerga.

O *gradient boosting* teve AUC de 0,927 (desvio-padrão de 0,005), contra 0,790 (0,004) da regressão logística, em linha com Lemmens e Croux (2006). Na importância por permutação, embaralhar o LTV reduz o AUC em 0,16 e as ligações ao atendimento, em 0,14, contra 0,06 da idade. Na regressão logística, o coeficiente do LTV ainda muda de sinal quando o total de compras entra no modelo, um efeito de supressão. A dependência parcial mostra por que o modelo de árvores vence: os efeitos são degraus, não retas (Figura 2). O churn previsto salta de

Figura 1 – Correlação de Spearman entre as 20 variáveis numéricas, ordenadas por agrupamento hierárquico



Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]). Valores exibidos quando $|\rho| \geq 0{,}3$.

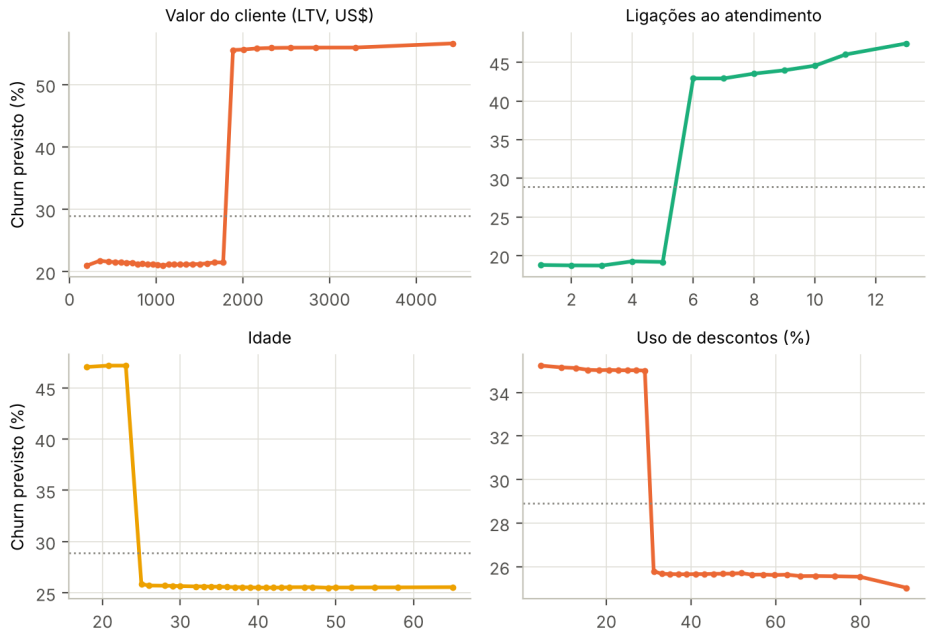
Tabela 1 – Churn por quintil e correlação com o churn, variáveis selecionadas

Variável	**Churn no 1º quintil**	**Churn no 5º quintil**	**ρ bruta**	**ρ parcial**
Ligações ao atendimento	12%	47%	+0,30	+0,19
Abandono de carrinho	19%	57%	+0,28	+0,10
Duração média da sessão	49%	19%	−0,23	−0,01
Abertura de e-mails	50%	18%	−0,23	−0,05
Dias desde a última compra	22%	40%	+0,14	+0,14
Valor do cliente (LTV)	45%	38%	−0,06	+0,21

Fonte: Elaboração própria. Quintil 1 = 20% dos clientes com menor valor da variável. Parcial = controlado o fator de engajamento.

19% para 43% entre 5 e 6 ligações ao atendimento e de 21% para 56% quando o LTV passa de cerca de US$ 1.800. Degraus tão nítidos, em valores redondos, indicam que o gerador da base definiu o churn por regras de corte.

Figura 2 – Dependência parcial: churn previsto ao longo das quatro variáveis mais importantes



Fonte: Elaboração própria a partir de SRISYRA02 ([2026?]). Linha pontilhada = taxa média de churn (28,9%).

5 CONCLUSÃO

A base analisada é simulada, e reconhecer isso foi o primeiro resultado do trabalho: uma auditoria simples bastou para mostrar, e também revelou que descartar as linhas incompletas teria retirado justamente os clientes com mais churn. Nela, o churn não depende do perfil demográfico, mas de um fator geral de engajamento, de sinais de atrito e, de forma não linear, do valor do cliente. Para a gestão, acompanhar oito indicadores de engajamento acrescenta pouco a acompanhar um índice que os resuma, enquanto ligações ao atendimento e abandono de carrinho apontam pontos de intervenção.

Três cuidados de método mudaram as conclusões: usar correlações robustas a extremos, controlar variáveis redundantes e testar modelos não lineares. Sem eles, o fator mais importante do churn, o LTV, teria parecido irrelevante. As limitações são a natureza simulada da base, o corte transversal, que impede saber se a queda de engajamento antecede o cancelamento, e o fato de associação não implicar causalidade.

REFERÊNCIAS

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, v. 57, n. 1, p. 289–300, 1995.

CRAMéR, H. *Mathematical methods of statistics*. Princeton: Princeton University Press, 1946.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

LEMMENS, A.; CROUX, C. Bagging and boosting classification trees to predict churn. *Journal of Marketing Research*, v. 43, n. 2, p. 276–286, 2006.

LITTLE, R. J. A.; RUBIN, D. B. *Statistical analysis with missing data*. 3. ed. Hoboken: Wiley, 2019.

NESLIN, S. A. et al. Defection detection: measuring and understanding the predictive accuracy of customer churn models. *Journal of Marketing Research*, v. 43, n. 2, p. 204–211, 2006.

REICHHELD, F. F.; SASSER, W. E. Zero defections: quality comes to services. *Harvard Business Review*, v. 68, n. 5, p. 105–111, 1990.

SILVA, J. G. T. *Análise de churn em e-commerce*. 2026. Notebook Jupyter. GitHub. Disponível em: <https://github.com/joaogabrielts0611-ai/Trabalho---PSP-8>. Acesso em: 5 nov. 2026.

SPEARMAN, C. The proof and measurement of association between two things. *The American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.

SRISYRA02. *Ecommerce customer behavior dataset*: a comprehensive analysis of customer behavior and engagement patterns. [2026?]. Kaggle. Base de dados. Disponível em: <https://www.kaggle.com/datasets/srisyra02/ecommerce-customer-behavior-dataset>. Acesso em: 5 nov. 2026.

VERBEKE, W. et al. New insights into churn prediction in the telecommunication sector: a profit driven data mining approach. *European Journal of Operational Research*, v. 218, n. 1, p. 211–229, 2012.